无线边缘网络中联邦学习通信效率优化方法研究综述

李嘉宇[1↑] 潘彦哲[1↑] 张振国[1↑] 周士栋[1↑]
[1] 电子科技大学 [↑] 共同第一作者

摘要：无线边缘网络中的联邦学习以模型交换替代原始数据汇聚，但频谱受限、信道时变和终端异构使多轮通信成为主要瓶颈。本文围绕通信轮数、参与节点、传输载荷、无线传输过程和网络组织方式，梳理客户端选择与频率控制、无线资源分配、模型压缩、空中计算和分层联邦学习五类方法，并比较其收益、代价、假设及适用场景。分析表明，各类方法作用于不同成本分量，通信收益通常以精度损失、控制开销、信道协同或部署复杂度为代价；跨层组合需统一核算比特量、时延、能耗和聚合误差。本文可为无线边缘场景下通信优化方法的选择与组合提供参考。

关键词：联邦学习；无线边缘网络；通信效率；空中计算；分层联邦学习

A Review of Communication-Efficiency Optimization Methods for Federated Learning in Wireless Edge Networks

Li Jiayu[1↑], Pan Yanzhe[1↑], Zhang Zhenguo[1↑], Zhou Shidong[1↑]
[1]University of Electronic Science and Technology of China [↑]Joint first authors.

Abstract: Federated learning replaces raw-data collection with iterative model exchange, yet limited spectrum, time-varying channels, and heterogeneous devices make communication a major bottleneck in wireless edge networks. This review organizes existing approaches according to the cost component they primarily affect: communication rounds and participating clients, radio-resource use, transmitted payload, over-the-air aggregation, and network hierarchy. Their benefits, additional costs, operating assumptions, and suitable deployment scenarios are compared under a common framework. The analysis shows that communication gains are commonly traded for learning distortion, control overhead, channel coordination, or deployment complexity. Consequently, cross-layer combinations should be evaluated through joint accounting of transmitted bits, latency, energy consumption, and aggregation error. The review provides a structured basis for selecting and combining communication-efficiency techniques in wireless edge federated learning.

Keywords: federated learning; wireless edge networks; communication efficiency; over-the-air computation; hierarchical federated learning

1 引言

联邦学习将原始数据保留在终端，通过周期性交换模型状态完成协同训练。其通信代价主要来自反复执行的模型下发和更新上传。经典联邦平均（Federated Averaging，FedAvg）在相邻两次聚合之间安排多步本地计算，以终端计算换取较少的全局同步[1]。

无线边缘网络会放大这一通信负担。参与设备共享有限频谱，链路质量随时间和位置变化；终端的算力、能量、在线状态及本地数据量也不一致。高维模型的多轮交换因而会占用带宽，延长训练等待时间，并消耗终端电量[2-4]。通信成本可先理解为“轮数、参与节点数与单次载荷”的累积，再由无线速率映射为时延和能耗。因此，通信效率不能只用单轮压缩倍数衡量，还应在相同学习目标下比较累计比特、墙钟时延和通信能耗。

现有综述已经从不同侧面建立了研究基础。移动边缘网络综述讨论通信成本、资源配置和隐私约束[2]，无线通信综述强调信道与接入资源对联邦训练的影响[3]。中文研究则分别梳理了边缘智能中的联邦学习、跨设备客户端选择及高效联邦学习方法[4-6]。这些工作的覆盖范围和分类尺度不同。若只并列算法名称，读者难以判断方法直接减少的是轮数、节点、载荷、传输时间还是长距离回传。

本文按照方法直接改变的通信成本分量组织文献。综述范围包括通信轮数、参与集合、传输载荷、无线传输过程和网络组织方式，并归纳为客户端选择与频率控制、无线资源分配、模型压缩、空中计算和分层拓扑五类。隐私、安全和激励只在其增加交互或资源约束时讨论。第 2节建立训练流程和评价口径，第 3节归纳五类方法，第 4节比较其收益、代价与适用场景，第 5节讨论共同问题与发展方向，第 6节给出结论。

2 无线边缘网络中的联邦学习通信模型与评价指标

2.1 系统模型与基本训练流程

中心式无线边缘联邦学习由聚合服务器和 K 个终端组成。服务器可位于接入点、边缘节点或云端；分层系统还设有边缘聚合层[7-8]。一次全局通信轮包含五个步骤：服务器下发当前模型，选择参与客户端；客户端使用本地数据训练若干步并上传更新；服务器聚合这些更新，得到下一轮模型。原

始数据留在终端，网络传输的是模型参数、梯度或编码结果[1]。

为说明各客户端的训练目标如何合成为全局目标，设终端 k 保存数据集 $\mathcal{D}_k=\{\xi_{k,i}\}_{i=1}^{n_k}$，其中 n_k 为样本数。全局经验风险写为各客户端局部损失的加权平均：

$$\begin{aligned}\min_{\boldsymbol{w}}\quad & F(\boldsymbol{w})=\sum_{k=1}^{K} q_k F_k(\boldsymbol{w}),\\ & F_k(\boldsymbol{w})=\frac{1}{n_k}\sum_{i=1}^{n_k}\ell(\boldsymbol{w};\xi_{k,i}),\\ & q_k=\frac{n_k}{N},\qquad N=\sum_{j=1}^{K} n_j.\end{aligned}\tag{2.1}$$

式中，$\boldsymbol{w}$ 为模型参数，ℓ 为单样本损失，F_k 为局部经验风险，q_k 为样本数权重，N 为总样本数。用普通语言说，样本较多的客户端对全局目标贡献更大。式 (2.1)也给出了通信优化的前提：减少通信后仍要达到约定的损失或精度目标。

设 t 为全局轮次，$\mathcal{S}_t$ 为参与集合，e 为本地更新步。客户端收到全局模型后，首先令本地初始模型 $\boldsymbol{w}_{k,t}^{(0)}=\boldsymbol{w}_t$。随后采用小批量随机梯度下降（stochastic gradient descent，SGD）：每一步只抽取一小批样本估计梯度，再沿降低损失的方向更新参数，

$$\begin{aligned}\boldsymbol{w}_{k,t}^{(0)}&=\boldsymbol{w}_t,\\ \boldsymbol{g}_{k,t}^{(e)}&=\frac{1}{|\mathcal{B}_{k,t}^{(e)}|}\sum_{\xi\in\mathcal{B}_{k,t}^{(e)}}\nabla\ell\left(\boldsymbol{w}_{k,t}^{(e)};\xi\right),\\ \boldsymbol{w}_{k,t}^{(e+1)}&=\boldsymbol{w}_{k,t}^{(e)}-\eta_t\boldsymbol{g}_{k,t}^{(e)}.\end{aligned}\tag{2.2}$$

其中，$\mathcal{B}_{k,t}^{(e)}$ 是第 e 步的小批量样本，$\boldsymbol{g}_{k,t}^{(e)}$ 是估计梯度，η_t 是学习率。式 (2.2)可以读作：客户端从服务器下发的同一模型出发，用本地小批量梯度逐步更新参数。它说明本地计算发生在两次通信之间，为后文讨论通信频率提供了基础。

客户端完成 E_k 步本地更新后，联邦平均（Federated Averaging，FedAvg）按参与客户端的数据量计算加权平均[1]：

$$\boldsymbol{w}_{t+1}=\sum_{k\in\mathcal{S}_t}\frac{n_k}{\sum_{j\in\mathcal{S}_t}n_j}\boldsymbol{w}_{k,t}^{(E_k)}.\tag{2.3}$$

式 (2.3)可以读作：服务器按参与客户端的样本数加权，得到下一轮全局模型。增加 E_k 不会取消当前轮的下发或上传，只会增加两次聚合之间的本地计算。若算法仍能收敛，它可能减少达到目标精度所需的全局轮数。非独立同分布（non-IID）指不同客户端的数据分布不相同。此时本地训练过多会使模型沿不同方向移动，形成“本地漂移”，并抵消减少同步的收益[1,9]。

2.2 通信成本分解与评价指标

通信效率需要多项指标描述。通信轮数是达到指定精度所需的全局同步次数；参与节点数是每轮上传的客户端数量；单轮比特量包括下发、上传和控制信令。墙钟时延是训练开始至达到目标精度的实际时间，包含计算、传输和同步等待；通信能耗则是无线收发消耗的能量。“发送得少”“发送得快”和“发送得省电”分别对应比特量、时延和能耗，不能相互替代。

为统一核算累计通信量，设 T 为达到预定精度或损失阈值所需的全局轮数，B_t^{dl} 为第 t 轮下行广播量，$B_{k,t}^{\mathrm{ul}}$ 为客户端 k 的上行载荷，$B_{k,t}^{\mathrm{ctl}}$ 为调度、索引和信道反馈等控制比特，则

$$B_{\mathrm{tot}}=\sum_{t=0}^{T-1}\left[B_t^{\mathrm{dl}}+\sum_{k\in\mathcal{S}_t}\left(B_{k,t}^{\mathrm{ul}}+B_{k,t}^{\mathrm{ctl}}\right)\right].\tag{2.4}$$

式 (2.4)可以读作：逐轮累加一次下行广播，以及所有参与客户端的上传和控制信息。**说明性示例**：若训练进行 2 轮，每轮下行广播 120 bit，3 个客户端各上传 100 bit 更新和 10 bit 控制信息，则累计通信量为 $2\times[120+3\times(100+10)]=900$ bit。该计算只用于解释公式，不是实验结果。它说明单轮载荷变小不保证 B_{tot} 下降；所需轮数或控制信息增加时，累计通信量仍可能上升[6]。

五类方法作用于式 (2.4)的不同部分。客户端选择与频率控制改变 $\mathcal{S}_t$ 和 T；模型压缩改变载荷，也可能增加索引等控制比特；无线资源分配通常不改变载荷，而是改变传输时间和能量。空中计算让多用户传输与聚合同时进行，更适合用信道占用时间和聚合误差衡量[4]。分层联邦学习改变消息路径，需要分别统计端—边和边—云通信。

无线链路把比特量进一步映射为时延和能耗。在一个信道状态近似不变的上行时隙内，令 $b_{k,t}$（Hz）为分配带宽，$P_{k,t}$（W）为发射功率，$h_{k,t}$ 为信道功率增益，N_0（W Hz^{-1}）为噪声功率谱密度，$I_{k,t}$（W）为干扰功率，则常用关系为[7,10]

$$R_{k,t}=b_{k,t}\log_2\left(1+\frac{P_{k,t}h_{k,t}}{N_0 b_{k,t}+I_{k,t}}\right),\tag{2.5a}$$

$$\tau_{k,t}^{\mathrm{ul}}=\frac{B_{k,t}^{\mathrm{ul}}}{R_{k,t}},\tag{2.5b}$$

$$E_{k,t}^{\mathrm{ul}}=P_{k,t}\tau_{k,t}^{\mathrm{ul}}.\tag{2.5c}$$

式 (2.5)中，$R_{k,t}$ 是上行速率，$\tau_{k,t}^{\mathrm{ul}}$ 是传输时延，$E_{k,t}^{\mathrm{ul}}$ 是发送能耗。三式可以依次读作：带宽、功率和信道条件决定速率；载荷除以速率得到发送时间；功率乘发送时间得到能耗。提高功率可能加快速率，却也提高单位时间功耗，所以总能耗未必下降。下行广播的比特量通常按基站一次发送统计，而广播时延可能由最慢接收客户端决定。前者统计发送多少，后者描述等待多久。后文讨论资源分配时将沿用这一区分[4,10]。

3 通信效率优化方法

由式 (2.4)和式 (2.5)可知，通信开销可以从参与节点、交互频率、单次载荷、无线传输过程和消息路径五个层面处理。下文以方法直接改变的变量为分类依据，而不按算法名称逐篇介绍。

3.1 客户端选择与通信频率控制

移动边缘训练中，可用设备常多于基站能够同时接入的数量，部分设备还会离线或逾期。客户端选择决定参与集合 $\mathcal{S}_t$，频率控制决定本地步数 E_k、触发条件和更新时序。两者分别回答“选谁”和“何时通信”，影响参与规模、全局轮数或等待时间。

客户端选择分为随机、资源感知和数据效用感知三类。随机选择无需详细状态，但可能选中慢设备。资源感知选择根据算力、电量、在线状态和信道质量，筛选能按期完成训练与上传的设备。数据效用感知还估计样本覆盖、局部损失或更新价值[5,11-13]。“快设备优先”虽能缩短等待，却会产生选择偏差：设备性能和位置可能与数据分布相关，长期排除弱设备会使参与数据偏离总体。

通信时序可分为同步、异步和事件触发机制。同步训练等待本轮更新到齐后再聚合，轮次时间受最慢参与者限制。异步训练允许更新到达后立即或分批采用，主要减少同步空等。更新陈旧度是客户端所用模型版本与服务器当前版本的差距，差距越大，更新越可能偏离当前方向。异步不必然减少累计上传；若每次更新仍单独发送，它减少的是等待而非比特。事件触发只在模型变化或梯度价值超过阈值时上传，才可能过滤冗余通信[14-15]。

相关研究已从“让本轮按期完成”扩展到长期公平和动态到达。FedCS 按资源状态选择设备，后续无线调度与长期选择再考虑信道、带宽和跨轮参与；自适应方法则按资源预算调整聚合周期[1,9,11-13]。异步边缘学习通过阈值或部分聚合抑制低价值更新，通信—计算重叠与公平调度用于减少等待并保留弱设备机会[14-16]。这些机制分别处理逾期参与、同步空等或冗余上传，并不同时降低所有指标。

这类方法需要状态上报和调度计算，还可能产生陈旧更新与公平性问题。随机选择适合设备条件相近的系统；资源感知选择适合期限严格的场景；数据效用感知适合数据差异明显且效用可估计的任务。异步机制适合设备间歇在线，但不适合对陈旧更新敏感的训练。参与集合确定后，设备仍要共享频谱，下一步还需配置无线与计算资源。

3.2 无线资源分配与联合优化

摄像头、车辆或手机共同训练时，弱信道或低算力终端仍会拖慢整轮训练。同步聚合需等待更新到齐，最慢终端的“本地计算时间加上传时间”常决定轮次完成时间。资源分配配置带宽 $b_{k,t}$、功率 $P_{k,t}$、接入时隙、中央处理器（CPU）频率和边缘关联，以改善传输时延、能耗或掉队率。

这些变量解决的问题不同。带宽决定频谱份额，功率影响接收质量与速率，时隙决定发送时间；三者作用于无线传输。CPU 频率改变本地计算速度和计算能耗，不直接进入上行速率式。边缘关联决定终端连接哪个基站或边缘服务器，进而影响链路质量、服务器负载和辅助计算位置。系统通常先收集信道、能量和计算状态，再在时延或能量约束下求解配置[7,10]。这些操作通常不减少 $B_{k,t}^{\mathrm{ul}}$，主要改变传完相同比特所需的时间和能量。

资源决策分为单轮配置和跨轮配置。单轮方法依据当前状态控制本轮时延、能耗或掉队数量，适合状态变化较慢且要求快速求解的场景。跨轮方法还考虑剩余电量、历史参与和未来信道，避免持续透支同一批设备。相关研究由此扩展到收敛约束、信道调度和长期客户端—带宽设计[7,10,12-13]。

多个联邦任务共享接入网时，资源配置还要在业务之间分配频谱。边缘辅助方案会同时决定弱终端是否由边缘侧辅助，并配置 CPU 频率、无线资源和模型稀疏度[17-18]。这类联合决策能同时处理通信等待、计算等待和长期能量约束，但变量增多会提高在线求解难度。在线学习或强化学习虽能适应动态状态，也会产生探索、训练和控制开销。

资源优化适合蜂窝边缘、多业务接入和设备差异明显的系统。若网络稳定、带宽充足或状态难以获取，复杂优化的收益可能不足以抵消开销。信道反馈占用控制比特，在线求解消耗时间和算力，求解期间状态变化还可能使配置过期。因此，反馈和调度应计入 $B_{k,t}^{\mathrm{ctl}}$，比特、时延和能耗也应分别报告。资源分配解决“怎样把更新传完”；若更新本身过大，还需用压缩削减载荷。

3.3 模型压缩与通信载荷削减

深度模型参数很多，即使信道较好，完整上传模型或梯度仍会占用大量带宽。模型压缩直接改变单轮载荷：量化减少每个数值使用的比特数，稀疏化减少需要发送的元素数量。量化先把连续数值映射到有限等级，再发送等级编码；稀疏化先按幅值或阈值保留少量重要元素，其余元素本轮不发送。两者可以组合，但会分别引入量化误差和丢弃误差。

为区分数学稀疏性与真实传输开销，设待传更新为 $\boldsymbol{g}_{k,t}\in\mathbb{R}^d$，稀疏算子为 $S(\cdot)$，本文定义

$$\begin{aligned}\sigma_{k,t}&=1-\frac{\|S(\boldsymbol{g}_{k,t})\|_0}{d},\\ \rho_{k,t}^{\mathrm{eff}}&=\frac{B_{k,t}^{\mathrm{val}}+B_{k,t}^{\mathrm{idx}}+B_{k,t}^{\mathrm{hdr}}}{B_{k,t}^{\mathrm{raw}}}.\end{aligned}\tag{3.1}$$

式 (3.1)第一行中，d 是原始元素总数，零范数 $\|\cdot\|_0$ 统计保留的非零元素数，$\sigma_{k,t}$ 表示被省略元素的比例。第二行比较实际编码量与未压缩载荷：B^{val} 是保留数值的比特，B^{idx} 是位置索引，B^{hdr} 是码长、形状等头部信息，B^{raw} 是原始载荷。有效传输比 $\rho_{k,t}^{\mathrm{eff}}$ 越小，真实节省越多。稀疏化必须发送索引，否则服

务器无法知道每个数值对应哪个参数；因此理论稀疏率高，不等于真实传输比一定同比降低。

误差反馈用于补偿暂未发送的信息。客户端把上一轮残差加入当前更新，再压缩上传；原更新与发送近似值之差留在本地，下一轮继续参与计算。被舍弃的小更新因而能在后续补偿。客户端为此需要保存残差并增加筛选或编码计算；终端频繁退出时，残差状态也难以连续维护[19-21]。

代表性工作体现了从单一压缩到自适应压缩的演进。FedPAQ 把周期平均、部分参与和量化放入同一框架；一比特压缩感知继续降低数值位宽，但需要稀疏先验和服务器重构[22-23]。稀疏三值压缩结合双向稀疏、低比特表示和误差累积，自适应方法则按训练状态调整保留比例；近期工作还同时选择稀疏度、量化级和能耗目标[18-21,24]。这些方法直接减少式 (2.4)中的载荷，而不是加快既定比特的传输。

压缩适合高维模型、窄上行且终端能够承担编码的场景。对小模型、短消息或弱算力设备，索引、头部和编解码成本可能抵消收益。压缩过强会增加优化误差，压缩感知或安全聚合还会引入重构、码本及额外交互[25]。评价时应同时报告累计比特、精度或损失、编解码成本，并说明是否计入索引。压缩回答“每个客户端发送多少”，空中计算则改变“多个客户端如何同时发送并聚合”。

3.4 空中计算与通信聚合融合

数字正交上传需要服务器分别恢复每个客户端的更新，因而通常为终端分配不同的时隙或子载波，避免数字码字相互干扰。服务器完成解码后再进行加权，而 FedAvg 等模型聚合本质上就是对客户端更新求加权和。无线多址信道又具有信号叠加特性：若终端把更新映射为模拟符号并同时发送，接收波形便包含这些符号的和。空中计算（over-the-air computation，AirComp）据此把“分别传输后求和”改为“传输过程中求和”[26-28]。两种机制如图 1所示。

为说明信道如何影响加权和，下面采用经过相位补偿的等效实数信道模型。对第 t 轮某一模型坐标，参与集合为 $\mathcal{S}_t$，终端 k 发送归一化更新 $x_{k,t}$，目标聚合权重为 $q_{k,t}$，则

$$y_t = \sum_{k\in\mathcal{S}_t} h_{k,t}\beta_{k,t}x_{k,t} + n_t, \tag{3.2a}$$

$$\widehat{s}_t = a_t y_t, \qquad s_t = \sum_{k\in\mathcal{S}_t} q_{k,t}x_{k,t}, \tag{3.2b}$$

$$e_t = \widehat{s}_t - s_t = \sum_{k\in\mathcal{S}_t}\big(a_t h_{k,t}\beta_{k,t} - q_{k,t}\big)x_{k,t} + a_t n_t. \tag{3.2c}$$

式 (3.2a)表示接收端看到所有终端信号与噪声的叠加。信道系数 $h_{k,t}$ 描述幅度变化，终端预编码 $\beta_{k,t}$ 用于发送前补偿，n_t 是接收噪声。式 (3.2b)中，接收缩放 a_t 调整整体幅度，$\widehat{s}_t$ 是实际估计，s_t 是目标加权和。式 (3.2c)进一步说明：聚合误差由系数未对齐和缩放后的噪声组成，理想对齐要求 $a_t h_{k,t}\beta_{k,t} \approx q_{k,t}$。这正是后文功率控制、设备选择和接收机设计需要减小的误差。

数字方案需要分离多用户信号，AirComp 则把受控叠加直接用作计算结果。它的收益来自无线资源复用，而不是无损压缩更新比特。

对齐并非总能实现。信道反演令预编码系数与 $h_{k,t}$ 近似成反比，但深衰落终端可能需要超过其最大发射功率。此时只能截断预编码、降低公共幅度或暂停该终端。信道估计不准会使 $a_t h_{k,t}\beta_{k,t}$ 偏离目标权重；载波频率、相位或符号时刻不同步，也会破坏同一坐标上的叠加。接收噪声则直接进入式 (3.2c)。这些因素形成的是聚合误差，不能简单依靠应用层重传消除。

AirComp 适合终端多、聚合函数可加、允许小幅模拟误差，且基站能获得较准信道信息并维持同步的场景。宽带及时变信道研究通过功率控制、设备选择和接收缩放降低聚合均方误差；稀疏一比特和分层 AirComp 还结合压缩或网络组织，但会叠加量化、信道与层级误差[29-31]。

若深衰落频繁、同步难以保证，或任务要求可靠恢复每个客户端更新，数字上传的独立解码与差错控制更稳妥。AirComp 主要减少多用户接入时间，不能理解为无条件、零误差或零能耗的聚合。

3.5 分层联邦学习与网络拓扑优化

终端直接连接中心云时，模型更新要跨越接入网和回传网。远距离链路增加时延、流量和掉线风险，云端还要等待分散终端。分层联邦学习把客户端按小区、位置或边缘关联划分为簇，由邻近边缘服务器先聚合。多数高频更新因而停留在端—边短链路，只有簇模型以较低频率经过边—云回传[8,32]。“端—边高频、边—云低频”表示一个云端轮次内进行多次簇内聚合，随后才同步云端，如图 2所示。

为区分三种时间尺度，令 t 表示云端轮次，$r = 1,\dots,H$ 表示其中的边缘聚合序号，$e = 0,\dots,E^{(r)}_{k,m,t}$ 表示本地 SGD 步数。这里 H 只表示每个云端轮次包含的边缘聚合次数，不表示本地步数。设系统有 M 个边缘簇，第 m 个簇的客户端集合为 $\mathcal{C}_{m,t}$，本地轨迹为 $\boldsymbol{u}^{(r,e)}_{k,m,t}$，最终本地模型记为 $\bar{\boldsymbol{u}}^{(r)}_{k,m,t} = \boldsymbol{u}^{(r,E^{(r)}_{k,m,t})}_{k,m,t}$。两级聚合可写为

$$\boldsymbol{w}^{(0)}_{m,t} = \boldsymbol{w}_t, \qquad \boldsymbol{u}^{(r,0)}_{k,m,t} = \boldsymbol{w}^{(r-1)}_{m,t}, \tag{3.3a}$$

$$N_{m,t} = \sum_{k\in\mathcal{C}_{m,t}} n_k, \qquad \boldsymbol{w}^{(r)}_{m,t} = \sum_{k\in\mathcal{C}_{m,t}} \frac{n_k}{N_{m,t}}\bar{\boldsymbol{u}}^{(r)}_{k,m,t}, \tag{3.3b}$$

$$N_t = \sum_{m=1}^{M} N_{m,t}, \qquad \boldsymbol{w}_{t+1} = \sum_{m=1}^{M} \frac{N_{m,t}}{N_t}\boldsymbol{w}^{(H)}_{m,t}. \tag{3.3c}$$

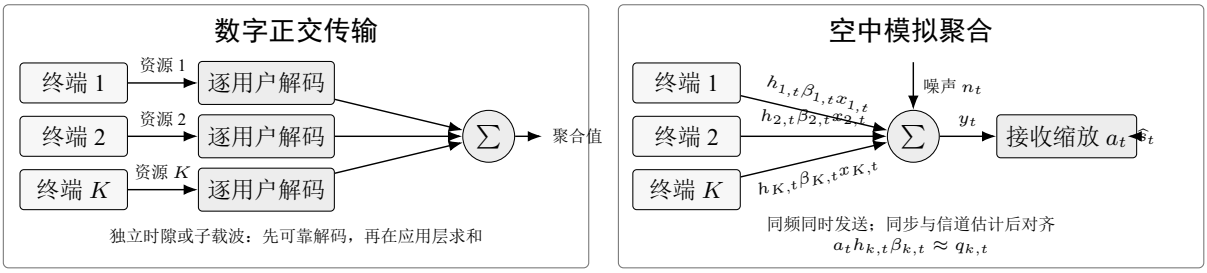


图 1 数字正交上传与空中聚合的机理差异[26-28]

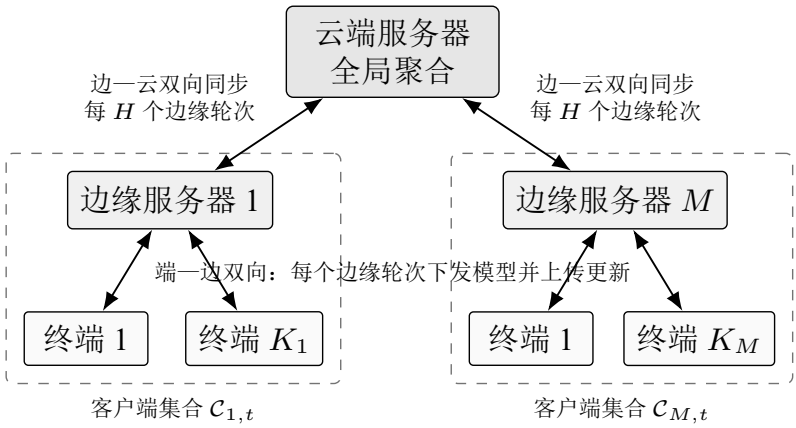


图 2 端—边—云双时间尺度聚合[8,32-33]

式 (3.3a)表示云模型先下发到边缘，并成为客户端的初始模型。式 (3.3b)表示边缘服务器按样本数汇总簇内模型。式 (3.3c)表示完成 H 次边缘聚合后，云端再把各簇模型合成为下一轮全局模型。三式依次对应图 2中的云端下发、端—边训练和边—云同步。

增大 H 会在两次云端同步之间执行更多簇内聚合，因此减少边—云同步频率。各簇也会沿自身数据分布独立演化更久；簇间数据差异较大时，边缘模型可能向不同方向移动，形成簇间漂移，并需要更多云端轮次重新对齐。客户端分簇会影响数据代表性，边缘负载不均会产生新的慢节点，终端移动还会改变集合 $\mathcal{C}_{m,t}$ 并增加模型迁移与控制通信。

分层方法适合多小区蜂窝、工业物联网和云—边—端集群，其收益取决于回传瓶颈、簇内数据分布和边缘可用性。量化分层可同时选择聚合间隔和消息精度；异构物联网方案还要处理异步到达、边缘负载和客户端选择[33-35]。端—边链路也可结合压缩或 AirComp，并用资源分配平衡各簇[31]。组合收益不能简单相加，需要分别核算两级比特、时延与能耗，并报告压缩误差、信道失真和层级漂移。

4 方法比较与适用场景分析

4.1 统一维度下的横向比较

横向比较需区分直接改变的变量与最终系统指标。图 3把式 (2.4)中的轮数、参与集合和上传载荷分别对应频率控制、客户端选择和压缩；速率与时延、并发聚合及消息路径则对应资源分配、AirComp 和分层联邦学习。

同一方法可能影响多个指标，但分类应以其直接控制的变量为准：压缩改变比特，资源分配改变速率和等待。表 1据此按“变量—原理—收益—代价”比较五类方法。

表 1表明，通信收益通常伴随成本转移：少参与带来偏差风险，压缩和 AirComp 引入失真，资源与分层优化增加控制开销。比特减少不必然缩短端到端时延，单轮加速也不保证总能耗下降[6-7]，因而不能脱离目标精度和无线基线判断最优类别。

4.2 场景匹配与方法组合

方法选择应先识别主导瓶颈，再决定是否组合多个优化层。表 2中的“优先”只表示先处理主导成本。若设备可用性还受参与意愿影响，激励应作为客户端选择的约束，而非新的通信类别[37]。

客户端选择与无线资源分配的组合同时回答“选谁”和“如何传”。前者筛除本轮难以完成训练的终端，后者为入选设备配置带宽、功率和时隙；但两层若都偏向快设备，会放大数据代表性偏差，状态上报与在线求解也会形成控制流量[11,13]。

稀疏化与 AirComp 同时降低有效维度和多用户接入时间。终端需协调稀疏位置或采用可聚合编码，否则不同支持集无法按坐标叠加；量化误差、残差近似、信道失配和噪声还会共同进入聚合误差[30]。

分层联邦与压缩先以低频云端同步减少回传次数，再压缩簇模型以降低单次回传载荷。两级压缩误差会与簇间漂移叠加，边缘侧还要承担编解码、簇管理和负载均衡[18,33]。因此，应分别核算端

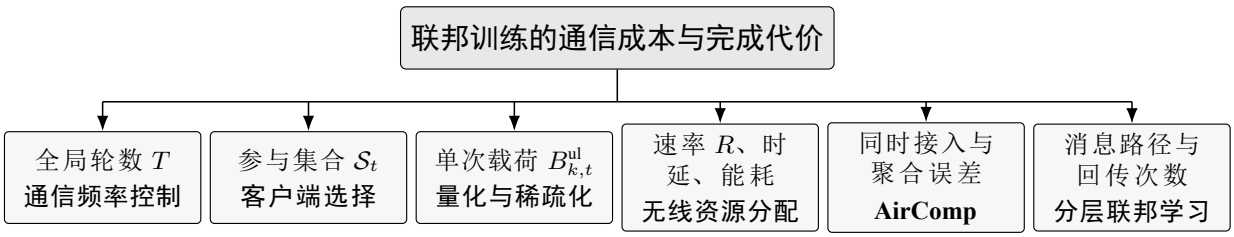


图 3 通信成本分量与五类优化方法的对应关系[2,4,6]

表 1 五类通信效率优化方法的原理比较

方法类别	主要改变的变量	基本原理	主要收益	主要代价
客户端选择与频率控制	$T, \mathcal{S}_t$ 及同步间隔	选择可用且有代表性的客户端，并按收敛状态调整同步或触发上传	减少等待；在满足收敛条件时可减少参与负载或全局轮数	状态上报、选择偏差、更新陈旧和本地漂移[5,9,11]
无线资源分配	带宽、功率、时隙、CPU 频率及边缘关联	根据信道和计算状态分配资源，使同步轮次中的慢终端不再长期主导完成时间	降低传输或计算时延，并在特定目标下改善能耗和掉队率	信道反馈、在线求解、控制信令及状态过期[10,17,36]
模型与梯度压缩	$B_{k,t}^{\mathrm{ul}}$、量化位宽和非零元素数	量化减少每个数值的位数，稀疏化减少发送元素，并用误差反馈补偿残差	直接减少载荷；在链路条件给定时缩短发送时间	量化失真、索引和码本开销、残差存储与编解码计算[19,22,24]
AirComp	并发接入时间、频谱占用及聚合误差	终端同步发送模拟更新，利用无线叠加在传输过程中形成加权和	多用户共享同一时频资源，减少密集接入的聚合等待	信道估计、同步、功率控制、噪声和失配误差[27,29-30]
分层联邦学习	消息路径、回传次数及两级聚合间隔 H	边缘侧高频聚合簇内更新，云端以较低频率聚合簇模型	减少长距离回传并提升多小区系统的扩展性	边缘部署、分组与迁移控制、负载不均和簇间漂移[8,33,35]

注：T 为全局轮数，$\mathcal{S}_t$ 为第 t 轮参与集合。表中收益均为条件性结论，不用于跨实验直接比较百分比。

—边和边—云开销，不能直接相加不同基线下的收益。

5 现存问题与发展趋势

5.1 现有研究的共同局限

指标口径不统一会限制横向比较。轮数、压缩率、时延、能耗和聚合误差衡量的对象不同；若目标精度以及控制消息、索引和重传的统计范围不同，相同“通信降低”并不表示相同系统收益[2,6,39]。

理想信道假设和终端异构都会限制部署结论。固定拓扑、准确信道状态和同步终端便于分析，但移动、深衰落和故障会改变参与集合、AirComp 对齐与分层归属[29,31]。设备能力还可能与数据分布相关，快设备优先、长期本地训练和固定分簇都可能造成统计偏差。

跨层组合会叠加误差和控制开销：压缩失真、信道噪声、更新陈旧与簇间漂移可能同时出现，状态反馈和在线求解也会消耗资源。区块链异步方案还需执行模型上链、共识和信誉评估，产生额外通信与计算[40]。秘密共享和安全传输同样只作为效率约束讨论，不构成独立主线[25,41]。

5.2 面向可部署系统的发展方向

发展方向应回应上述限制。在线跨层方法需要让客户端选择、压缩程度、无线资源和边缘关联随训练阶段与信道变化，同时计入决策时间和反馈比特[13,24,31]。面向异构终端的方法还要同时处理设备能力、模型规模和数据分布差异。边缘辅助与集群蒸馏依赖额外边缘算力或代理知识，其收益仍需跨场景验证[18,38,42]。

面向任务的消息设计不再要求每轮传输完整参数。单轮通信方案让客户端上传生成模型，由服务器生成模拟数据并训练全局模型[43]；集群蒸馏则交换任务知识[42]。这类证据仍受具体任务和生成质量限制。可复现实验应在相同目标精度下报告累计比特、墙钟时延、能耗、控制开销和聚合误差，并公开信道轨迹、数据划分与重复设置。

6 结论

通信效率方法可归纳为客户端选择与频率控制、无线资源分配、模型压缩、AirComp 和分层拓扑五类。它们分别作用于轮数与参与节点、传输载荷、无线过程和消息路径，也会引入统计偏差、失真、控制信令或部署复杂度。窄带高维模型可优先考虑压缩；密集且同步条件可控的接入场景可考虑 AirComp；多小区或回传受限系统更适合分层聚合。组合方法应先确定主导瓶颈，再在同一目标精度下分别核算比特、时延、能耗和误差，不能把不同实验基线下的收益直接相加。

表 2 不同无线边缘场景下的方法选择

主导瓶颈	典型场景	优先考虑的方法	选择理由	使用时需要注意的问题
同步等待与终端异构	大规模物联网；设备能力和在线状态差异明显	客户端选择＋资源分配	同时控制“谁参与”和“如何完成本轮传输”，缓解慢终端造成的等待	快设备优先会造成选择偏差；状态采集和联合求解也有开销[11,13]
高维更新与窄上行	视觉模型、移动终端或低速上行链路	量化、稀疏化及误差反馈	直接减少每轮需要编码和发送的更新量	需计入索引、码本和残差；压缩误差可能增加训练轮数[19,22]
密集终端同时接入	同步条件可控、聚合函数可加的蜂窝或传感网络	AirComp；必要时结合稀疏化	在同一时频资源中完成多用户叠加，避免逐用户正交接入	依赖信道估计、同步与功率可行性，并引入聚合误差[27,30]
回传链路受限	多小区、工业园区或云—边—端集群	分层联邦＋两级压缩	先减少边—云同步频率，再降低簇模型的回传载荷	需联合控制量化误差、簇间漂移和边缘负载[33,38]
多瓶颈随时间变化	移动、多业务竞争或时变信道环境	跨轮选择、压缩和资源联合优化	可随训练阶段和网络状态切换主要优化变量	在线决策、反馈和模型迁移可能抵消部分通信收益[13,24,31]

参考文献

[1] McMahan B, Moore E, Ramage D, et al. Communication-Efficient Learning of Deep Networks from Decentralized Data[C/OL]// Proceedings of Machine Learning Research: Proceedings of the 20th International Conference on Artificial Intelligence and Statistics: vol. 54. 2017: 1273-1282. https://proceedings.mlr.press/v54/mcmahan17a.html.

[2] Lim W Y B, Luong N C, Hoang D T, et al. Federated Learning in Mobile Edge Networks: A Comprehensive Survey[J/OL]. IEEE Communications Surveys & Tutorials, 2020, 22(3): 2031-2063. DOI: 10.1109/COMST.2020.2986024.

[3] Niknam S, Dhillon H S, Reed J H. Federated Learning for Wireless Communications: Motivation, Opportunities, and Challenges[J/OL]. IEEE Communications Magazine, 2020, 58(6): 46-51. DOI: 10.1109/MCOM.001.1900461.

[4] 张雪晴, 刘延伟, 刘金霞, 等. 面向边缘智能的联邦学习综述[J/OL]. 计算机研究与发展, 2023, 60(6): 1276-1295. DOI: 10.7544/issn1000-1239.202111100.

[5] 张瑞麟, 杜晋华, 尹浩. 跨设备联邦学习中的客户端选择算法[J/OL]. 软件学报, 2024, 35(12): 5725-5740. DOI: 10.13328/j.cnki.jos.007085.

[6] 葛丽娜, 王明禹, 田蕾. 联邦学习的高效性研究综述[J/OL]. 计算机应用, 2025, 45(8): 2387-2398. DOI: 10.11772/j.issn.1001-9081.2024081119.

[7] Tran N H, Bao W, Zomaya A Y, et al. Federated Learning Over Wireless Networks: Optimization Model Design and Analysis[C/OL]// IEEE INFOCOM 2019 – IEEE Conference on Computer Communications. 2019: 1387-1395. DOI: 10.1109/INFOCOM.2019.8737464.

[8] Liu L, Zhang J, Song S, et al. Client-Edge-Cloud Hierarchical Federated Learning[C/OL]//2020 IEEE International Conference on Communications (ICC). 2020: 1-6. DOI: 10.1109/ICC40277.2020.9148862.

[9] Wang S, Tuor T, Salonidis T, et al. Adaptive Federated Learning in Resource Constrained Edge Computing Systems[J/OL]. IEEE Journal on Selected Areas in Communications, 2019, 37(6): 1205-1221. DOI: 10.1109/JSAC.2019.2904348.

[10] Dinh C T, Tran N H, Nguyen M N H, et al. Federated Learning Over Wireless Networks: Convergence Analysis and Resource Allocation [J/OL]. IEEE/ACM Transactions on Networking, 2021, 29(1): 398-409. DOI: 10.1109/TNET.2020.3035770.

[11] Nishio T, Yonetani R. Client Selection for Federated Learning with Heterogeneous Resources in Mobile Edge[C/OL]//2019 IEEE International Conference on Communications (ICC). 2019: 1-7. DOI: 10.1109/ICC.2019.8761315.

[12] Yang H H, Liu Z, Quek T Q S, et al. Scheduling Policies for Federated Learning in Wireless Networks[J/OL]. IEEE Transactions on Communications, 2020, 68(1): 317-333. DOI: 10.1109/TCOMM.2019.2944169.

[13] Xu J, Wang H. Client Selection and Bandwidth Allocation in Wireless Federated Learning Networks: A Long-Term Perspective[J/OL]. IEEE Transactions on Wireless Communications, 2021, 20(2): 1188-1200. DOI: 10.1109/TWC.2020.3031503.

[14] 芦效峰, 廖钰盈, Lio P, 等. 一种面向边缘计算的高效异步联邦学习机制[J/OL]. 计算机研究与发展, 2020, 57(12): 2571-2582. DOI: 10.7544/issn1000-1239.2020.20190754.

[15] Liu J, Xu H, Xu Y, et al. Communication-Efficient Asynchronous Federated Learning in

Resource-Constrained Edge Computing[J/OL]. Computer Networks, 2021, 199: 108429. DOI: 10.1016/j.comnet.2021.108429.

[16] Ozfatura M E, Zhao J, Gündüz D. Fast Federated Edge Learning with Overlapped Communication and Computation and Channel-Aware Fair Client Scheduling[C/OL]//2021 IEEE 22nd International Workshop on Signal Processing Advances in Wireless Communications (SPAWC). 2021: 311-315. DOI: 10.1109/SPAWC51858.2021.9593130.

[17] Xu J, Wang H, Chen L. Bandwidth Allocation for Multiple Federated Learning Services in Wireless Edge Networks[J/OL]. IEEE Transactions on Wireless Communications, 2022, 21(4): 2534-2546. DOI: 10.1109/TWC.2021.3113346.

[18] 陈晓, 仇洪冰, 李燕龙. 边缘辅助的自适应稀疏联邦学习优化算法[J/OL]. 电子与信息学报, 2025, 47(3): 645-656. DOI: 10.11999/JEIT240741.

[19] Sattler F, Wiedemann S, Müller K R, et al. Robust and Communication-Efficient Federated Learning from Non-i.i.d. Data[J/OL]. IEEE Transactions on Neural Networks and Learning Systems, 2020, 31(9): 3400-3413. DOI: 10.1109/TNNLS.2019.2944481.

[20] Han P, Wang S, Leung K K. Adaptive Gradient Sparsification for Efficient Federated Learning: An Online Learning Approach[C/OL]//2020 IEEE 40th International Conference on Distributed Computing Systems (ICDCS). 2020: 300-310. DOI: 10.1109/ICDCS47774.2020.00026.

[21] 田金箫. 提升联邦学习通信效率的梯度压缩算法[J/OL]. 计算机系统应用, 2022, 31(10): 199-205. DOI: 10.15888/j.cnki.csa.008748.

[22] Reisizadeh A, Mokhtari A, Hassani H, et al. FedPAQ: A Communication-Efficient Federated Learning Method with Periodic Averaging and Quantization[C/OL]//Proceedings of Machine Learning Research: Proceedings of the 23rd International Conference on Artificial Intelligence and Statistics: vol. 108. 2020: 2021-2031. https://proceedings.mlr.press/v108/reisizadeh20a.html.

[23] 章振宇, 谭国平, 周思源. 基于 1-bit 压缩感知的高效无线联邦学习算法[J/OL]. 计算机应用, 2022, 42(6): 1675-1682. DOI: 10.11772/j.issn.1001-9081.2021061374.

[24] Marnissi O, El Hammouti H, Bergou E H. Adaptive Sparsification and Quantization for Enhanced Energy Efficiency in Federated Learning[J/OL]. IEEE Open Journal of the Communications Society, 2024, 5: 4307-4321. DOI: 10.1109/OJCOMS.2024.3425531.

[25] 陈律君, 肖迪, 余柱阳, 等. 基于秘密共享和压缩感知的通信高效联邦学习[J/OL]. 计算机研究与发展, 2022, 59(11): 2395-2407. DOI: 10.7544/issn1000-1239.20220526.

[26] Amiri M M, Gündüz D. Machine Learning at the Wireless Edge: Distributed Stochastic Gradient Descent Over-the-Air[C/OL]//2019 IEEE International Symposium on Information Theory (ISIT). 2019: 1432-1436. DOI: 10.1109/ISIT.2019.8849334.

[27] Zhu G, Wang Y, Huang K. Broadband Analog Aggregation for Low-Latency Federated Edge Learning[J/OL]. IEEE Transactions on Wireless Communications, 2020, 19(1): 491-506. DOI: 10.1109/TWC.2019.2946245.

[28] 朱光旭, 李航. 面向高效通信边缘学习网络的通信计算一体化设计[J/OL]. 中兴通讯技术, 2020, 26(4): 23-30. https://zxtx.cbpt.cnki.net/portal/journal/portal/client/paper/25c48c3c86cd8dbabd990499071ff8c6.

[29] Tegin B, Duman T M. Federated Learning With Over-the-Air Aggregation Over Time-Varying Channels[J/OL]. IEEE Transactions on Wireless Communications, 2023, 22(8): 5671-5684. DOI: 10.1109/TWC.2023.3235894.

[30] Oh J, Lee D, Won D, et al. Communication-Efficient Federated Learning Over-the-Air With Sparse One-Bit Quantization[J/OL]. IEEE Transactions on Wireless Communications, 2024, 23(10): 15673-15689. DOI: 10.1109/TWC.2024.3432758.

[31] Azimi-Abarghouyi S M, Fodor V. Scalable Hierarchical Over-the-Air Federated Learning [J/OL]. IEEE Transactions on Wireless Communications, 2024, 23(8): 8480-8496. DOI: 10.1109/TWC.2024.3350923.

[32] Abad M S H, Ozfatura E, Gündüz D, et al. Hierarchical Federated Learning Across Heterogeneous Cellular Networks[C/OL]//2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). 2020: 8866-8870. DOI: 10.1109/ICASSP40776.2020.9054634.

[33] Liu L, Zhang J, Song S, et al. Hierarchical Federated Learning With Quantization: Convergence Analysis and System Design[J/OL]. IEEE Transactions on Wireless Communications, 2023, 22(1): 2-18. DOI: 10.1109/TWC.2022.3190512.

[34] 唐伦, 汪智平, 蒲昊, 等. 基于自适应梯度压缩的高效联邦学习通信机制研究[J/OL]. 电子与信息学报, 2023, 45(1): 227-234. DOI: 10.11999/JEIT211262.

[35] 王汝言, 陈伟, 张普宁, 等. 异构物联网下资源高效的分层协同联邦学习方法[J/OL]. 电子与信息学报, 2023, 45(8): 2847-2855. DOI: 10.11999/JEIT220914.

[36] 范露露, 倪郑威, 李职杜. 联邦学习网络中基

于分层博弈的边缘关联和资源分配[J/OL]. 重庆邮电大学学报（自然科学版）, 2025, 37(2): 261-272. https://cjournal.hep.com.cn/1673-825X/CN/1160179240370102516.

[37] 贾云健, 黄宇, 梁靓, 等. 基于主从博弈的分层联邦学习激励机制研究[J/OL]. 电子与信息学报, 2023, 45(4): 1366-1373. DOI: 10.11999/JEIT220175.

[38] 钟正仪, 包卫东, 吴冠霖, 等. 一种面向云边端系统的分层异构联邦学习方法[J/OL]. 计算机研究与发展, 2022, 59(11): 2408-2422. DOI: 10.7544/issn1000-1239.20220458.

[39] Mills J, Hu J, Min G. Communication-Efficient Federated Learning for Wireless Edge Intelligence in IoT[J/OL]. IEEE Internet of Things Journal, 2020, 7(7): 5986-5994. DOI: 10.1109/JIOT.2019.2956615.

[40] 黄晓舸, 邓雪松, 陈前斌, 等. 边缘计算网络中区块链赋能的异步联邦学习算法[J/OL]. 电子与信息学报, 2024, 46(1): 195-203. DOI: 10.11999/JEIT221517.

[41] 孟涛, 窦艳菲, 孙强, 等. 无人机辅助联邦学习安全传输能效优化[J/OL]. 无线电工程, 2025, 55(9): 1861-1868. https://wxdg.cbpt.cnki.net/portal/journal/portal/client/paper/4fe4319debd9959f5fd3d3337f847ae5.

[42] Zhang J, An Z, Wang X, et al. FedCD: A Communication-Efficient Federated Learning Framework via Hierarchical Cluster-Distillation for Heterogeneous Edge Clients[J/OL]. Computer Networks, 2026, 288: 112611. DOI: 10.1016/j.comnet.2026.112611.

[43] 郑赛, 李天瑞, 黄维. 面向通信成本优化的联邦学习算法[J/OL]. 计算机应用, 2023, 43(1): 1-7. DOI: 10.11772/j.issn.1001-9081.2021122054.