无线边缘网络中联邦学习通信效率优化方法研究综述

作者姓名
（作者单位，四川成都 610000）

A Review of Communication-Efficiency Optimization Methods for Federated Learning in Wireless Edge Networks

Author Name
Affiliation, Chengdu 610000, China

摘要：无线边缘网络中的联邦学习以模型交换替代原始数据汇聚，但频谱受限、信道时变和终端异构使多轮通信成为主要瓶颈。本文围绕通信轮数、参与节点、传输载荷、无线传输过程和网络组织方式，梳理客户端选择与频率控制、无线资源分配、模型压缩、空中计算和分层联邦学习五类方法，并比较其收益、代价、假设及适用场景。分析表明，各类方法作用于不同成本分量，通信收益通常以精度损失、控制开销、信道协同或部署复杂度为代价；跨层组合需统一核算比特量、时延、能耗和聚合误差。本文可为无线边缘场景下通信优化方法的选择与组合提供参考。

关键词：联邦学习；无线边缘网络；通信效率；空中计算；分层联邦学习

Abstract: Federated learning replaces raw-data collection with iterative model exchange, yet limited spectrum, time-varying channels, and heterogeneous devices make communication a major bottleneck in wireless edge networks. This review organizes existing approaches according to the cost component they primarily affect: communication rounds and participating clients, radio-resource use, transmitted payload, over-the-air aggregation, and network hierarchy. Their benefits, additional costs, operating assumptions, and suitable deployment scenarios are compared under a common framework. The analysis shows that communication gains are commonly traded for learning distortion, control overhead, channel coordination, or deployment complexity. Consequently, cross-layer combinations should be evaluated through joint accounting of transmitted bits, latency, energy consumption, and aggregation error. The review provides a structured basis for selecting and combining communication-efficiency techniques in wireless edge federated learning.

Keywords: federated learning; wireless edge networks; communication efficiency; over-the-air computation; hierarchical federated learning

1 引言

联邦学习通过保留终端本地数据、周期性交换模型状态来完成协同训练，其通信代价来自反复执行的模型下发与更新上传。经典联邦平均（Federated Averaging，FedAvg）在相邻两次聚合之间安排多步本地计算，从而以终端计算换取较少的全局同步[1]。然而，在无线边缘网络中，参与设备共享有限频谱，链路质量随时间和位置变化，终端的算力、能量、在线状态及本地数据量也不一致；高维模型的多轮交换因而会同时占用带宽、延长训练等待时间并消耗电池能量[2-4]。通信效率不能仅用单轮压缩倍数表示，还应在相同学习目标下联合考察通信轮数、传输比特数、墙钟时延和通信能耗。

现有综述已经从不同侧面建立了研究基础。移动边缘网络综述系统讨论通信成本、资源配置和隐私约束[2]，无线通信综述强调信道与接入资源对联邦训练的影响[3]；中文研究则分别梳理了边缘智能中的联邦学习、跨设备客户端选择及高效联邦学习方法[4-6]。这些工作的覆盖范围和分类尺度并不相同，直接并列算法名称难以判断某种方法究竟减少了轮数、节点、载荷、传输时间还是长距离回传。

本文据此将通信成本组成与系统作用层次结合起来组织文献。综述范围限定为直接改变通信轮数、参与集合、传输载荷、无线传输过程或网络组织方式的方法，并按客户端选择与频率控制、无线资源分配、模型压缩、空中计算和分层拓扑五类展开；隐私、安全和激励仅在其引入额外交互或资源约束时简要讨论。第 2节建立训练流程和评价口径，第 3节归纳五类方法，第 4节比较其收益、代价与适用场景，第 5节讨论共同问题与发展方向，第 6节给出结论。

2 无线边缘网络中的联邦学习通信模型与评价指标

2.1 系统模型与基本训练流程

中心式无线边缘联邦学习通常包含一个聚合服务器和 K 个终端，服务器可部署在接入点、边缘节点或云端，分层系统还可在边缘与云之间增加第二级聚合[7-8]。第 k 个终端保存数据集 $\mathcal{D}_k = \{\xi_{k,i}\}_{i=1}^{n_k}$，其中 n_k 为样本数；训练时数据不离开终

端，网络传输的是模型参数、梯度或其编码表示[1]。为统一后续方法的学习约束，全局经验风险写为

$$\begin{aligned}\min_{\boldsymbol{w}} \quad & F(\boldsymbol{w})=\sum_{k=1}^{K} q_k F_k(\boldsymbol{w}),\\ & F_k(\boldsymbol{w})=\frac{1}{n_k}\sum_{i=1}^{n_k}\ell(\boldsymbol{w};\xi_{k,i}),\\ & q_k=\frac{n_k}{N},\qquad N=\sum_{j=1}^{K} n_j.\end{aligned}\tag{2.1}$$

式中，$\boldsymbol{w}$ 为全局模型参数，F_k 为终端 k 的局部经验风险，ℓ 为单样本损失，q_k 为按样本数确定的聚合权重，N 为总样本数。式 (2.1)表明，通信削减必须以维持学习目标为约束，不能把少传数据本身等同于训练有效。

一轮训练由模型下发、本地更新、更新上传和服务器聚合组成。设 t 为全局通信轮，$\mathcal{S}_t$ 为参与集合，e 为本地步，$\mathcal{B}_{k,t}^{(e)}\subseteq\mathcal{D}_k$ 为终端 k 的小批量样本，终端以学习率 η_t 执行随机梯度下降

$$\begin{aligned}\boldsymbol{g}_{k,t}^{(e)}&=\frac{1}{|\mathcal{B}_{k,t}^{(e)}|}\sum_{\xi\in\mathcal{B}_{k,t}^{(e)}}\nabla\ell\left(\boldsymbol{w}_{k,t}^{(e)};\xi\right),\\ \boldsymbol{w}_{k,t}^{(e+1)}&=\boldsymbol{w}_{k,t}^{(e)}-\eta_t\boldsymbol{g}_{k,t}^{(e)}.\end{aligned}\tag{2.2}$$

完成 E_k 步后，FedAvg 按参与终端的数据量聚合为[1]

$$\boldsymbol{w}_{t+1}=\sum_{k\in\mathcal{S}_t}\frac{n_k}{\sum_{j\in\mathcal{S}_t}n_j}\boldsymbol{w}_{k,t}^{(E_k)}.\tag{2.3}$$

式 (2.2)和式 (2.3)把本地步数、参与规模与聚合权重联系起来：增加 E_k 或缩小 $\mathcal{S}_t$ 可减少当期交互，却可能改变更新时效性和数据代表性，后续比较需同时记录其学习代价。

2.2 通信成本分解与评价指标

累计通信量需要把轮数、参与规模、上下行载荷及控制信令置于同一口径。设 T 为达到预定精度或损失阈值所需的全局轮数，B_t^{dl} 为第 t 轮下行广播量，$B_{k,t}^{\mathrm{ul}}$ 和 $B_{k,t}^{\mathrm{ctl}}$ 分别为终端 k 的上行载荷与调度、索引或信道反馈等控制比特，则本文采用

$$B_{\mathrm{tot}}=\sum_{t=0}^{T-1}\left[B_t^{\mathrm{dl}}+\sum_{k\in\mathcal{S}_t}\left(B_{k,t}^{\mathrm{ul}}+B_{k,t}^{\mathrm{ctl}}\right)\right].\tag{2.4}$$

式 (2.4)是统一比较口径而非某种算法的性能结论；其中下行默认按基站一次广播的空口发送量统计，若按全部终端的接收总量核算，则必须相应计入接收节点数。该式说明，减少单轮载荷只有在没有显著增加 T 或控制开销时，才会降低累计通信量[6]。

无线链路进一步把比特量映射为时延和能耗。对准静态上行时隙，令 $b_{k,t}$（Hz）、$P_{k,t}$（W）、$h_{k,t}$ 分别表示分配带宽、发射功率和等效信道功率增益，N_0（$\mathrm{W\,Hz^{-1}}$）为噪声功率谱密度，$I_{k,t}$（W）为带内干扰功率，则常用抽象关系为[7,9]

$$R_{k,t}=b_{k,t}\log_2\left(1+\frac{P_{k,t}h_{k,t}}{N_0 b_{k,t}+I_{k,t}}\right),\tag{2.5a}$$

$$\tau_{k,t}^{\mathrm{ul}}=\frac{B_{k,t}^{\mathrm{ul}}}{R_{k,t}},\tag{2.5b}$$

$$E_{k,t}^{\mathrm{ul}}=P_{k,t}\tau_{k,t}^{\mathrm{ul}}.\tag{2.5c}$$

式 (2.5)中，$R_{k,t}$（$\mathrm{bit\,s^{-1}}$）、$\tau_{k,t}^{\mathrm{ul}}$（s）和 $E_{k,t}^{\mathrm{ul}}$（J）分别为上行速率、传输时延和发送能耗。由此可见，压缩主要改变 $B_{k,t}^{\mathrm{ul}}$，资源分配主要改变 $R_{k,t}$，客户端与频率控制改变 T 和 $\mathcal{S}_t$，分层架构则改变消息路径；这些量必须在相同精度目标和明确无线假设下比较，才能判断端到端通信效率是否真正提高[4,9]。

3 通信效率优化方法

由式 (2.4)和式 (2.5)可知，通信开销可以从参与节点、交互频率、单次载荷、无线传输过程和消息路径五个层面削减。本节前半部分依次讨论前三类中的客户端与频率控制、无线资源分配以及模型压缩，并以优化变量而非算法名称组织比较。

3.1 客户端选择与通信频率控制

客户端选择首先处理“设备很多但每轮无法全部接入”的瓶颈，其直接变量是参与集合 $\mathcal{S}_t$ 及其规模。资源感知方法以计算能力、在线状态和完成时限筛除可能拖慢聚合的终端，信道感知方法则把链路质量纳入调度；进一步的长期设计还联合带宽约束和跨轮参与机会[10-12]。这些方法的共同点是提高单次上传的可完成性和信息效用，差异在于资源优先会偏向“快设备”，数据效用优先则可能选中通信代价较高的终端[5]。

通信频率控制进一步改变本地步数 E_k、触发条件和更新到达时序。固定多步本地训练以计算换取较少全局轮次，自适应方法根据资源预算调整聚合周期，异步方法则允许终端独立上传，并通过阈值、陈旧度权重或通信—计算重叠减少等待和冗余更新[1,13-16]。这一演进使控制对象由“选谁”扩展为“何时上传、服务器何时采用”，但也引入本地漂移和陈旧更新。

因此，该类方法适合设备数量大、间歇在线且算力差异明显的物联网和移动边缘场景，收益主要体现为参与上传数、同步轮数及等待时间下降。其代价是状态上报信令、选择偏差和长期公平性；若弱信道或少数数据分布的终端持续被排除，较低通信量未必对应相同学习目标。与压缩或带宽分配组合时，还需避免“少参与”和“少信息”叠加放大统计偏差[5,12]。

3.2 无线资源分配与联合优化

参与者确定后，无线接入的核心瓶颈转为共享频谱、有限发射功率和慢终端造成的轮次时延。该类方法优化带宽 $b_{k,t}$、功率 $P_{k,t}$、中央处理器

（CPU）频率、接入时隙或边缘关联，主要通过提高式 (2.5a)中的速率、降低式 (2.5b)和式 (2.5c)中的时延与能耗来改善训练，而不一定减少待传比特。早期无线联邦学习模型已将局部计算精度、计算资源和上行传输纳入统一约束，后续工作进一步结合收敛条件和信道调度处理学习—通信耦合[7,9,11]。

资源优化随后由单轮、单业务配置扩展到跨轮和多业务联合决策。长期方案同时考虑客户端选择与带宽，使当前轮的低时延选择受到能量预算和未来参与机会约束；多联邦学习业务并存时，还需在服务之间分配频谱，而边缘辅助方案可把弱终端训练、通信资源与模型稀疏度共同决策[12,17-18]。前两类通常依赖可解释的优化模型，在线学习或强化学习更能适应动态状态，但会增加训练、探索和控制开销。

这类方法适用于蜂窝边缘、多任务接入和信道快速变化的系统，其收益是降低最大轮次时延、发送能耗或掉队概率；主要限制则是信道状态反馈、在线求解复杂度和公平性。特别是“最快终端优先”虽可缩短当轮时间，却可能损害数据代表性，因而资源配置应与选择策略联合评价，并把控制信令计入 $B_{k,t}^{\mathrm{ctl}}$ [9,12]。

3.3 模型压缩与通信载荷削减

模型压缩直接针对高维参数或梯度导致的单次载荷过大问题，其变量是保留元素数量和每个元素的编码比特数。为区分数学稀疏性与真实传输开销，设待传更新为 $\boldsymbol{g}_{k,t}\in\mathbb{R}^d$，压缩算子为 $Q(\cdot)$，本文定义

$$\begin{aligned}\sigma_{k,t}&=1-\frac{\|Q(\boldsymbol{g}_{k,t})\|_0}{d},\\ \rho_{k,t}^{\mathrm{eff}}&=\frac{B_{k,t}^{\mathrm{val}}+B_{k,t}^{\mathrm{idx}}+B_{k,t}^{\mathrm{hdr}}}{B_{k,t}^{\mathrm{raw}}}.\end{aligned}\tag{3.1}$$

式 (3.1)中，$\sigma_{k,t}$ 为稀疏率，B^{val}、B^{idx} 和 B^{hdr} 分别为数值、索引和头部比特，B^{raw} 为未压缩载荷；$\rho_{k,t}^{\mathrm{eff}}$ 是有效传输比，节省比例为 $1-\rho_{k,t}^{\mathrm{eff}}$。因此，稀疏率提高并不保证端到端比特量同比下降。

量化与稀疏化的共同目标是降低 $B_{k,t}^{\mathrm{ul}}$，但误差来源不同。量化把连续更新映射到有限精度表示，FedPAQ 将周期平均、部分参与和量化置于同一框架；一比特压缩感知则进一步压低数值位宽，但要求服务器利用稀疏先验恢复更新[19-20]。稀疏化保留 Top-k 或超过阈值的元素，稀疏三值压缩还结合双向压缩和误差累积，自适应方法则随训练状态在线选择保留比例[21-23]。前者主要承担量化噪声，后者还要传输位置索引；误差反馈能够缓解被丢弃更新的累积偏差，却增加客户端状态和计算。

压缩方法适合模型维度高、上行带宽紧张或电池受限的终端，并容易与客户端选择和资源分配组合。近期研究开始联合调整稀疏度、量化级和能耗目标，边缘辅助方案也会按设备状态改变剪枝与资源配置[18,24]。其局限在于压缩误差、解码或重构成本以及索引、码本和安全交互等附加载荷；例如压缩感知与秘密共享结合时，隐私保护会引入额外计算和消息[25]。因此，应以式 (2.4)中的累计通信量和相同精度目标评价压缩，而不能只比较单轮理论压缩倍数。

3.4 空中计算与通信聚合融合

空中计算（over-the-air computation，AirComp）改变了“先传输、后聚合”的数字通信流程。数字正交上传为各终端分配时隙或子载波，接收端分别完成信道解码，再在应用层求和；其可靠性边界清晰，但接入资源和聚合等待通常随参与设备增多。AirComp 则使终端在同一资源块同步发送模拟映射后的更新，利用多址信道的波形叠加直接获得加权和，从而把传输与聚合合并[26-28]。两种机制的差异如图 1所示。

AirComp 的建模目的，是同时表示目标聚合值、信道失真与接收噪声。对某一模型坐标，设第 t 轮参与集合为 $\mathcal{S}_t$，终端 k 发送归一化更新 $x_{k,t}$，其目标权重为 $q_{k,t}$，则接收与估计关系可写为

$$y_t=\sum_{k\in\mathcal{S}_t}h_{k,t}\beta_{k,t}x_{k,t}+n_t,\tag{3.2a}$$

$$\widehat{s}_t=a_t y_t,\qquad s_t=\sum_{k\in\mathcal{S}_t}q_{k,t}x_{k,t},\tag{3.2b}$$

$$e_t=\widehat{s}_t-s_t=\sum_{k\in\mathcal{S}_t}\big(a_t h_{k,t}\beta_{k,t}-q_{k,t}\big)x_{k,t}+a_t n_t.\tag{3.2c}$$

式中，$h_{k,t}$ 为上行信道系数，$\beta_{k,t}$ 为终端预编码系数，n_t 为接收噪声，a_t 为接收端缩放系数，e_t 为聚合误差。式 (3.2c)表明，低时延叠加并非“零代价聚合”：信道估计误差、载波与符号不同步、受限功率下的不完全信道反演以及噪声都会造成失真。

因此，AirComp 的收益取决于物理层条件及学习任务对聚合误差的容忍度。宽带与时变信道研究通过功率控制、设备选择和接收缩放抑制均方误差；稀疏一比特量化和分层 AirComp 则把载荷压缩或网络组织与模拟聚合结合，但同时叠加量化、信道和层级误差[29-31]。该机制适合大量终端同时接入、聚合函数可加且基站能够实施精确信道协同的无线边缘场景；在深衰落、严格可靠传输或同步条件不足时，数字正交方案仍更稳健。

3.5 分层联邦学习与网络拓扑优化

分层联邦学习针对终端直接连接中心云所产生的长距离回传和跨域等待，将客户端按小区、地理位置或边缘关联划分为多个簇，由边缘服务器先聚合，再以较低频率向云端上传簇模型[8,32]。如图 2所示，端—边链路承担高频局部交换，边—云链路承担低频全局同步；它优化的是消息路径和聚合位置，而不是消除通信本身。

为表达两级权重和通信频率，设系统含 M 个边缘簇，第 m 个簇在第 t 个云端周期内完成 H 次

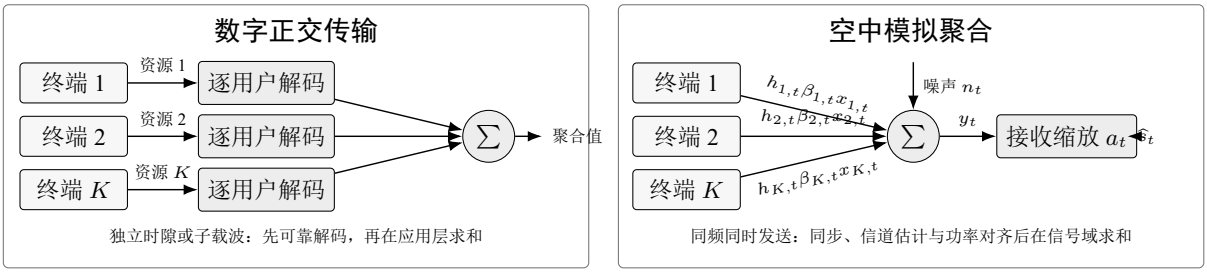


图 1 数字正交上传与空中聚合的机理差异（作者根据文献[26-28]归纳绘制；原创图，未直接复用或改编第三方图片）

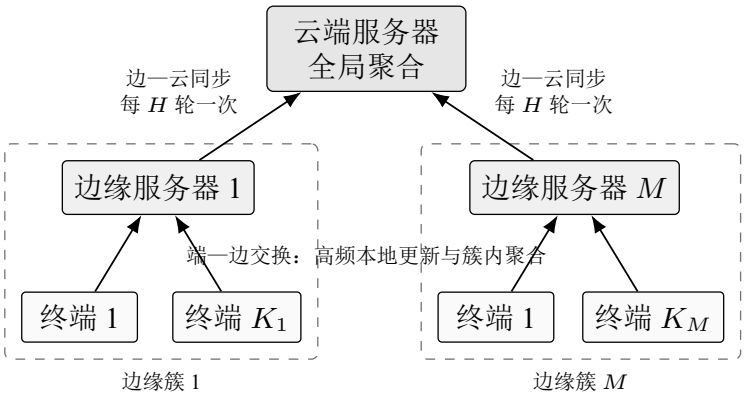


图 2 端—边—云双时间尺度聚合（作者根据文献[8,32-33]归纳绘制；原创图，未直接复用或改编第三方图片）

边缘聚合，其客户端集合为 $\mathcal{C}_{m,t}$。客户端 k 的样本数为 n_k，第 r 次本地训练后的模型为 $\boldsymbol{w}_{k,m,t}^{(r)}$，则

$$N_{m,t}=\sum_{k\in\mathcal{C}_{m,t}} n_k, \qquad \boldsymbol{w}_{m,t}^{(r)}=\sum_{k\in\mathcal{C}_{m,t}} \frac{n_k}{N_{m,t}}\boldsymbol{w}_{k,m,t}^{(r)}, \tag{3.3a}$$

$$N_t=\sum_{m=1}^{M} N_{m,t}, \qquad \boldsymbol{w}_{t+1}=\sum_{m=1}^{M} \frac{N_{m,t}}{N_t}\boldsymbol{w}_{m,t}^{(H)}. \tag{3.3b}$$

式 (3.3a)表示簇内边缘聚合，式 (3.3b)表示每 H 次边缘聚合后的云端聚合。增大 H 可减少边—云回传次数，但也会使不同簇沿各自数据分布继续训练更久，扩大边缘模型漂移；因而远距离通信节省与全局收敛不能分开评价。

分层设计的关键代价是新增的分组、调度和层间协调。量化分层方法联合设置两级聚合间隔与消息精度，异构物联网方案还需处理边缘能力差异、异步到达和客户端选择；其收益往往由多个组件共同产生，不能归因于单一聚合层[33-35]。因此，该类方法适合多小区蜂窝、工业物联网和云—边—端集群，但簇内非独立同分布数据会造成边缘聚合偏差，动态节点归属、边缘负载和故障还会增加控制通信。它可以与压缩、AirComp 和资源分配组合[31]，前提是分别核算端—边与边—云开销，并统一分析压缩误差、信道失真和层级漂移。

4 方法比较与适用场景分析

4.1 统一维度下的横向比较

横向比较需在相同目标精度下区分“少传多少”和“更快传完”。客户端选择改变轮数和参与规模，压缩改变载荷，资源分配与 AirComp 改变无线传输，分层架构改变消息路径。通信降幅需结合数据、信道和基线比较，表 1据此比较五类方法。

表 1表明，通信收益通常是成本转移：本地计算带来漂移，少参与带来选择偏差，压缩和 AirComp 引入失真，资源与分层优化增加控制开销。上传比特减少不必然缩短时延，单轮加速也不保证总能耗降低[6-7]，因而不存在脱离系统条件的最优类别。

4.2 场景匹配与方法组合

方法选择应从主导瓶颈出发。设备异构或参与意愿受限时，宜先控制参与和等待，再配置无线资源[12,39]；模型大而上行窄时优先压缩，生成模型驱动的单轮通信则依赖生成数据质量和额外计算[40]。密集可控接入可考虑 AirComp，多小区或回传受限系统更适合分层聚合、边缘关联和模型适配[36,38]。

组合收益不能简单相加：稀疏 AirComp 同时包含压缩与信道误差，分层 AirComp 还叠加簇间漂移；边缘辅助也需要额外计算和控制[18,30-31]。组合设计应把精度、控制比特、计算和部署条件纳入同一目标。

5 现存问题与发展趋势

5.1 现有研究的共同局限

现有研究的共同不足是口径和假设不统一：轮数、压缩率、时延、能耗与聚合误差并存，若不说

表 1 五类通信效率优化方法的统一比较

方法类别	优化对象	代表机制	主要收益	额外代价	关键假设	适用场景	主要局限
客户端选择与频率控制	$T, \mathcal{S}_t, E_k$	效用选择；异步或事件触发	少上传、少同步、少等待	状态上报、偏差与陈旧	状态可观测；更新具代表性	大规模异构物联网	弱设备可能长期缺席，影响公平与收敛[5,10,13]
无线资源分配	带宽、功率、时隙、CPU 频率及边缘关联	跨轮资源与关联联合调度	降低时延、能耗和掉队率	信道反馈、求解和信令	状态可估计；链路模型有效	蜂窝、多业务、无人机网络	改变传输效率但未必减少累计比特[9,17,36-37]
模型与梯度压缩	$B_{k,t}^{\mathrm{ul}}$、稀疏度和量化位宽	量化、稀疏、误差反馈	减少载荷和发送能耗	失真、索引和重构计算	更新可压缩；误差可补偿	高维模型、窄带终端	理论压缩率不等于有效传输比[19,21,24]
AirComp	多用户上传时间、频谱及聚合误差	同步模拟发送；波形域求和	传输与聚合并行	信道状态、同步、功控、噪声	函数可加；物理层可协同	密集同步无线接入	深衰落和时变信道会破坏对齐[27,29-30]
分层联邦学习	消息路径、簇划分及两级聚合间隔 H	边缘高频、云端低频聚合	少回传、易扩展	部署、分组、控制和漂移	边缘可用；簇权重合理	多小区、云—边—端集群	簇偏差、节点迁移和故障增加协调难度[8,33,35,38]

注：T 为全局轮数，$\mathcal{S}_t$ 为参与集合，E_k 为本地步数；表中内容不用于比较不同实验设置中的百分比。

明目标精度及控制消息，结论难以复现[2,6,41]。不少方案仍基于固定拓扑、受控信道和标准数据集，对移动、故障及多业务竞争验证不足[29,31]。秘密共享、区块链共识和安全传输只作为效率约束，会增加交互、计算或能耗[25,37,42]。

5.2 面向可部署系统的发展方向

未来研究需要跨层在线协同，使选择、压缩、无线资源、聚合方式和边缘关联随信道与训练阶段共同调整，同时限制决策开销[12,24,31]。异构适配还应联合处理设备能力、模型规模和数据分布；异构模型适配、边缘辅助与集群蒸馏分别依赖边缘算力或代理数据，仍需跨场景验证[18,38,43]。

面向任务的消息设计尝试用生成数据或蒸馏知识替代完整参数[40,43]，但证据仍依赖特定数据、模型和代理知识，尚未形成统一类别。后续实验应报告目标精度下的累计比特、时延、能耗、控制开销和聚合误差，并公开信道、数据划分与重复设置，以支持端到端复现。

6 结论

通信效率方法可归纳为客户端选择与频率控制、无线资源分配、模型压缩、AirComp 和分层拓扑五类。它们分别作用于轮数、参与节点、载荷、无线传输和消息路径，并以计算负担、统计偏差、失真、控制信令或部署复杂度为代价。窄带高维模型宜压缩，密集可控接入可考虑 AirComp，多小区和回传受限系统宜分层聚合。后续需在统一精度目标下核算比特、时延、能耗和误差，并以动态环境和可复现实验检验组合方案。

参考文献

[1] McMahan B, Moore E, Ramage D, et al. Communication-Efficient Learning of Deep Networks from Decentralized Data[C/OL]// Proceedings of Machine Learning Research: Proceedings of the 20th International Conference on Artificial Intelligence and Statistics: vol. 54. 2017: 1273-1282. https://proceedings.mlr.press/v54/mcmahan17a.html.

[2] Lim W Y B, Luong N C, Hoang D T, et al. Federated Learning in Mobile Edge Networks: A Comprehensive Survey[J/OL]. IEEE Communications Surveys & Tutorials, 2020, 22(3): 2031-2063. DOI: 10.1109/COMST.2020.2986024.

[3] Niknam S, Dhillon H S, Reed J H. Federated Learning for Wireless Communications: Motivation, Opportunities, and Challenges[J/OL]. IEEE Communications Magazine, 2020, 58(6): 46-51. DOI: 10.1109/MCOM.001.1900461.

[4] 张雪晴, 刘延伟, 刘金霞, 等. 面向边缘智能的联邦学习综述[J/OL]. 计算机研究与发展, 2023, 60(6): 1276-1295. DOI: 10.7544/issn1000-1239.202111100.

[5] 张瑞麟, 杜晋华, 尹浩. 跨设备联邦学习中的客户端选择算法[J/OL]. 软件学报, 2024, 35(12): 5725-5740. DOI: 10.13328/j.cnki.jos.007085.

[6] 葛丽娜, 王明禹, 田蕾. 联邦学习的高效性研究综述[J/OL]. 计算机应用, 2025, 45(8): 2387-2398. DOI: 10.11772/j.issn.1001-9081.2024081119.

[7] Tran N H, Bao W, Zomaya A Y, et al. Federated Learning Over Wireless Networks: Optimization Model Design and Analysis[C/OL]// IEEE INFOCOM 2019 – IEEE Conference on Computer Communications. 2019: 1387-1395. DOI: 10.1109/INFOCOM.2019.8737464.

[8] Liu L, Zhang J, Song S, et al. Client-Edge-Cloud Hierarchical Federated Learning[C/OL]//2020 IEEE International Conference on Communications (ICC). 2020: 1-6. DOI: 10.1109/ICC40277.2020.9148862.

[9] Dinh C T, Tran N H, Nguyen M N H, et al. Federated Learning Over Wireless Networks: Convergence Analysis and Resource Allocation [J/OL]. IEEE/ACM Transactions on Networking, 2021, 29(1): 398-409. DOI: 10.1109/TNET.2020.3035770.

[10] Nishio T, Yonetani R. Client Selection for Federated Learning with Heterogeneous Resources in Mobile Edge[C/OL]//2019 IEEE International Conference on Communications (ICC). 2019: 1-7. DOI: 10.1109/ICC.2019.8761315.

[11] Yang H H, Liu Z, Quek T Q S, et al. Scheduling Policies for Federated Learning in Wireless Networks[J/OL]. IEEE Transactions on Communications, 2020, 68(1): 317-333. DOI: 10.1109/TCOMM.2019.2944169.

[12] Xu J, Wang H. Client Selection and Bandwidth Allocation in Wireless Federated Learning Networks: A Long-Term Perspective[J/OL]. IEEE Transactions on Wireless Communications, 2021, 20(2): 1188-1200. DOI: 10.1109/TWC.2020.3031503.

[13] Wang S, Tuor T, Salonidis T, et al. Adaptive Federated Learning in Resource Constrained Edge Computing Systems[J/OL]. IEEE Journal on Selected Areas in Communications, 2019, 37(6): 1205-1221. DOI: 10.1109/JSAC.2019.2904348.

[14] 芦效峰, 廖钰盈, Lio P, 等. 一种面向边缘计算的高效异步联邦学习机制[J/OL]. 计算机研究与发展, 2020, 57(12): 2571-2582. DOI: 10.7544/issn1000-1239.2020.20190754.

[15] Liu J, Xu H, Xu Y, et al. Communication-Efficient Asynchronous Federated Learning in Resource-Constrained Edge Computing[J/OL]. Computer Networks, 2021, 199: 108429. DOI: 10.1016/j.comnet.2021.108429.

[16] Ozfatura M E, Zhao J, Gündüz D. Fast Federated Edge Learning with Overlapped Communication and Computation and Channel-Aware Fair Client Scheduling[C/OL]//2021 IEEE 22nd International Workshop on Signal Processing Advances in Wireless Communications (SPAWC). 2021: 311-315. DOI: 10.1109/SPAWC51858.2021.9593130.

[17] Xu J, Wang H, Chen L. Bandwidth Allocation for Multiple Federated Learning Services in Wireless Edge Networks[J/OL]. IEEE Transactions on Wireless Communications, 2022, 21(4): 2534-2546. DOI: 10.1109/TWC.2021.3113346.

[18] 陈晓, 仇洪冰, 李燕龙. 边缘辅助的自适应稀疏联邦学习优化算法[J/OL]. 电子与信息学报, 2025, 47(3): 645-656. DOI: 10.11999/JEIT240741.

[19] Reisizadeh A, Mokhtari A, Hassani H, et al. FedPAQ: A Communication-Efficient Federated Learning Method with Periodic Averaging and Quantization[C/OL]//Proceedings of Machine Learning Research: Proceedings of the 23rd International Conference on Artificial Intelligence and Statistics: vol. 108. 2020: 2021-2031. https://proceedings.mlr.press/v108/reisizadeh20a.html.

[20] 章振宇, 谭国平, 周思源. 基于 1-bit 压缩感知的高效无线联邦学习算法[J/OL]. 计算机应用, 2022, 42(6): 1675-1682. DOI: 10.11772/j.issn.1001-9081.2021061374.

[21] Sattler F, Wiedemann S, Müller K R, et al. Robust and Communication-Efficient Federated Learning from Non-i.i.d. Data[J/OL]. IEEE Transactions on Neural Networks and Learning

Systems, 2020, 31(9): 3400-3413. DOI: 10.1109/TNNLS.2019.2944481.

[22] Han P, Wang S, Leung K K. Adaptive Gradient Sparsification for Efficient Federated Learning: An Online Learning Approach[C/OL]//2020 IEEE 40th International Conference on Distributed Computing Systems (ICDCS). 2020: 300-310. DOI: 10.1109/ICDCS47774.2020.00026.

[23] 田金箫. 提升联邦学习通信效率的梯度压缩算法[J/OL]. 计算机系统应用, 2022, 31(10): 199-205. DOI: 10.15888/j.cnki.csa.008748.

[24] Marnissi O, El Hammouti H, Bergou E H. Adaptive Sparsification and Quantization for Enhanced Energy Efficiency in Federated Learning[J/OL]. IEEE Open Journal of the Communications Society, 2024, 5: 4307-4321. DOI: 10.1109/OJCOMS.2024.3425531.

[25] 陈律君, 肖迪, 余柱阳, 等. 基于秘密共享和压缩感知的通信高效联邦学习[J/OL]. 计算机研究与发展, 2022, 59(11): 2395-2407. DOI: 10.7544/issn1000-1239.20220526.

[26] Amiri M M, Gündüz D. Machine Learning at the Wireless Edge: Distributed Stochastic Gradient Descent Over-the-Air[C/OL]//2019 IEEE International Symposium on Information Theory (ISIT). 2019: 1432-1436. DOI: 10.1109/ISIT.2019.8849334.

[27] Zhu G, Wang Y, Huang K. Broadband Analog Aggregation for Low-Latency Federated Edge Learning[J/OL]. IEEE Transactions on Wireless Communications, 2020, 19(1): 491-506. DOI: 10.1109/TWC.2019.2946245.

[28] 朱光旭, 李航. 面向高效通信边缘学习网络的通信计算一体化设计[J/OL]. 中兴通讯技术, 2020, 26(4): 23-30. https://zxtx.cbpt.cnki.net/portal/journal/portal/client/paper/25c48c3c86cd8dbabd990499071ff8c6.

[29] Tegin B, Duman T M. Federated Learning With Over-the-Air Aggregation Over Time-Varying Channels[J/OL]. IEEE Transactions on Wireless Communications, 2023, 22(8): 5671-5684. DOI: 10.1109/TWC.2023.3235894.

[30] Oh J, Lee D, Won D, et al. Communication-Efficient Federated Learning Over-the-Air With Sparse One-Bit Quantization[J/OL]. IEEE Transactions on Wireless Communications, 2024, 23(10): 15673-15689. DOI: 10.1109/TWC.2024.3432758.

[31] Azimi-Abarghouyi S M, Fodor V. Scalable Hierarchical Over-the-Air Federated Learning [J/OL]. IEEE Transactions on Wireless Communications, 2024, 23(8): 8480-8496. DOI: 10.1109/TWC.2024.3350923.

[32] Abad M S H, Ozfatura E, Gündüz D, et al. Hierarchical Federated Learning Across Heterogeneous Cellular Networks[C/OL]//2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). 2020: 8866-8870. DOI: 10.1109/ICASSP40776.2020.9054634.

[33] Liu L, Zhang J, Song S, et al. Hierarchical Federated Learning With Quantization: Convergence Analysis and System Design[J/OL]. IEEE Transactions on Wireless Communications, 2023, 22(1): 2-18. DOI: 10.1109/TWC.2022.3190512.

[34] 唐伦, 汪智平, 蒲昊, 等. 基于自适应梯度压缩的高效联邦学习通信机制研究[J/OL]. 电子与信息学报, 2023, 45(1): 227-234. DOI: 10.11999/JEIT211262.

[35] 王汝言, 陈伟, 张普宁, 等. 异构物联网下资源高效的分层协同联邦学习方法[J/OL]. 电子与信息学报, 2023, 45(8): 2847-2855. DOI: 10.11999/JEIT220914.

[36] 范露露, 倪郑威, 李职杜. 联邦学习网络中基于分层博弈的边缘关联和资源分配[J/OL]. 重庆邮电大学学报（自然科学版）, 2025, 37(2): 261-272. https://cjournal.hep.com.cn/1673-825X/CN/1160179240370102516.

[37] 孟涛, 窦艳菲, 孙强, 等. 无人机辅助联邦学习安全传输能效优化[J/OL]. 无线电工程, 2025, 55(9): 1861-1868. https://wxdg.cbpt.cnki.net/portal/journal/portal/client/paper/4fe4319debd9959f5fd3d3337f847ae5.

[38] 钟正仪, 包卫东, 吴冠霖, 等. 一种面向云边端系统的分层异构联邦学习方法[J/OL]. 计算机研究与发展, 2022, 59(11): 2408-2422. DOI: 10.7544/issn1000-1239.20220458.

[39] 贾云健, 黄宇, 梁靓, 等. 基于主从博弈的分层联邦学习激励机制研究[J/OL]. 电子与信息学报, 2023, 45(4): 1366-1373. DOI: 10.11999/JEIT220175.

[40] 郑赛, 李天瑞, 黄维. 面向通信成本优化的联邦学习算法[J/OL]. 计算机应用, 2023, 43(1): 1-7. DOI: 10.11772/j.issn.1001-9081.2021122054.

[41] Mills J, Hu J, Min G. Communication-Efficient Federated Learning for Wireless Edge Intelligence in IoT[J/OL]. IEEE Internet of Things Journal, 2020, 7(7): 5986-5994. DOI: 10.1109/JIOT.2019.2956615.

[42] 黄晓舸, 邓雪松, 陈前斌, 等. 边缘计算网络中区块链赋能的异步联邦学习算法[J/OL]. 电子与信息学报, 2024, 46(1): 195-203. DOI: 10.11999/JEIT221517.

[43] Zhang J, An Z, Wang X, et al. FedCD: A Communication-Efficient Federated Learning Framework via Hierarchical Cluster-Distillation for Heterogeneous Edge Clients[J/OL]. Computer Networks, 2026, 288: 112611. DOI: 10.1016/j.comnet.2026.112611.